

FINAL METHOD

문장 조건부 4-프레임 시간 순서 복원

Qwen3.5-9B에 유효 순열 제한 생성과 라벨 보존 입력 순열 증강을 결합한 자동 단일 모델

0.85863

Public Exact Match

전체 train 재학습 자동 모델

0.51888

2개 독립 fold pooled

1,979 / 3,814

0

수동 수정·양상불·TTA

최종 제출 추론 기준

문제 정의와 동기

입력은 시간 순서가 뒤섞인 4개 프레임과 사건 흐름을 설명하는 문장이다. 가능한 답은 24개지만 평가는 네 위치가 모두 맞아야만 1점인 Exact Match다. 일반 VLM의 자유 생성은 장면을 설명할 수 있어도 숫자 중복·누락, 제출 의미의 역변환 오류, 국소 선후관계와 전체 순열의 불일치를 동시에 일으킨다. 따라서 이 문제를 설명 생성이 아니라 **문장에 조건화된 구조화 순열 생성**으로 다시 정의했다.

핵심 기여

1 태스크 정렬 디코딩

별도 24-class head 대신 사전학습 LM head를 보존하고, earliest-to-latest 입력 번호를 생성한다. 순열 trie가 매 단계 남은 번호만 허용하므로 출력은 항상 유효하다.

2 입력 위치 편향 제어

epoch마다 정확히 25% 샘플의 입력 4장을 비하당 순열로 바꾸고 정답도 함께 변환한다. 원 데이터의 no-order prior는 75%에서 보존한다.

3 독립 재현 기반 선택

중복 그룹이 겹치지 않는 Fold 0:1을 같은 설정으로 학습했다. 두 Exact 차이는 0.00052였다. 한 패널에서만 오른 TTA와 exact-24는 최종 모델에서 제외했다.

최종 파이프라인

문장 +
4개 프레임

입력

→

비율 보존
224 px² 상한

전처리

→

Qwen3.5-9B
LoRA 0.46%

인코딩

→

순열 trie
제한 생성

디코딩

→

Answer 역변환
CSV

출력

데이터·평가 계약

Train	Test	정답 공간	평가	최종 추론
9,535 samples	819 samples	24 permutations	Exact Match	single model

성능 주장 경계

최종 0.85863은 train 9,535개로 학습한 하나의 adapter가 만든 자동 Public 결과다. test 개별 답 수정, 수동 검토 라벨, 외부 API·외부 학습 데이터, fold ensemble은 사용하지 않았다. 모델 선택은 Public 점수가 아니라 고정 train-only validation과 독립 fold 재현으로 수행했다.

01 / METHOD

24개 순열을 이해하는 생성 모델

시각-언어 추론 능력은 사전학습 모델에서 가져오고, 출력 공간과 학습 신호를 대회 지표에 맞게 제한했다.

입력 표현과 라벨 의미

프롬프트 순서

문장 → Input image 1·2·3·4 → earliest-to-latest 출력 지시. 문장을 먼저 제시해 각 이미지 토큰이 사건 흐름을 참조하게 한다. 객체 상태, 동작, 장면 전환, 시각적 연속성을 함께 보도록 명시했다.

라벨 왕복 변환

대회 Answer는 각 입력 이미지가 시간상 몇 번째인지 나타낸다. 모델은 해석이 자연스러운 '시간순 입력 번호'를 생성하고, 저장 직전에 Answer 형식으로 역변환한다. 단위 테스트로 24개 전 순열의 왕복 변환을 검증했다.

예시

Answer [2,1,4,3]

모델 target 2 1 4 3

각 입력의 rank ↔ 시간순 입력 index

유효 순열 제한 생성

순열 trie: 매 단계에서 남은 숫자만 허용



중복·누락·파싱 실패 확률 = 0 | 24개 가능한 전체 순열만 생성

Qwen tokenizer에서 24개 문자열(예: '1 3 2 4')의 token sequence를 미리 만들고 trie로 구성한다. greedy decoding의 각 step에서 현재 prefix와 이어질 수 있는 token만 남긴다. 이 방식은 자유 텍스트 파싱이나 후처리 보정 없이 **parse rate 1.0**, **24개 class 사용**, **항상 완전한 순열**을 보장한다. 학습은 정답 token에 대한 causal cross-entropy를 사용해 추론 구조와 일치시켰다.

Parameter-efficient adaptation

구성	최종 설정	설계 이유
Backbone	Qwen/Qwen3.5-9B, pinned revision	통합 vision-language-video understanding 기반
학습 영역	Language attention-MLP + VL merger LoRA	시각 tower는 고정해 작은 데이터 과적합 억제
LoRA	rank 16, alpha 32, dropout 0.05	43.57M / 9.45B = 0.46%만 학습
입력	비율 보존, crop 없음, 최대 224' pixels	네 프레임을 단일 장치에서 안정적으로 처리
수치-메모리	BF16, SDPA, gradient checkpointing	M1 Max 64GB에서 학습·추론 완료

라벨 보존 입력 순열 증강

원순서 정답은 train의 1,478/9,535(15.50%)로 다른 개별 순열보다 훨씬 많다. 이를 모두 균등화하면 실제 prior를 지우고, 증강하지 않으면 입력 위치 shortcut이 남는다. 그래서 각 epoch에서 샘플 ID와 seed로 결정되는 **정확한 25%**만 비항등 순열로 재배치하고 정답을 함께 변환했다. 75%는 원 입력을 유지해 두 위험을 동시에 완화했다.

02 / TRAINING

선택과 최종 학습을 분리한 검증 계약

test 점수로 답을 고치지 않고, train-only 독립 재현을 통과한 설정만 전체 학습으로 승격했다.

데이터 진단과 분할

항목	Train	Test	설계 반영
샘플 / 이미지	9,535 / 38,140	819 / 3,276	샘플마다 4프레임
이미지 형식	JPEG 38,140	JPEG 2,312 + PNG 964	비율 보존·crop 제거
문장 길이(중앙값)	26 words	33 words	원문 prompt 유지
원문서 비율	1,478 / 9,535 = 15.50%	정답 미공개	25% 순열 증강
정답 공간	24개 모두 존재	24개 중 하나	완전 순열 제한

동일·유사 샘플의 누수를 줄이기 위해 group 단위 5-fold manifest를 고정했다. 최종 설정 검증은 서로 겹치지 않는 Fold 0·1(각 train 7,628, validation 1,907)에서 같은 seed·설정으로 독립 실행했다.

실험에서 최종 모델까지

1 Locked screen 대표 B256에서 구조·backbone을 비교	2 Fold 0 1,907개 전체 holdout으로 일반화 확인	3 Independent Fold 1 설정 고정 후 재학습·재현	4 Full refit train 9,535개, 1 epoch, fresh base	5 Test inference 단일 adapter-greedy-no TTA
---	---	---	--	---

독립 fold 재현 결과

검증	Exact Match	Non-identity	Identity	Pairwise	Position	Parse / classes
Fold 0	0.51914	0.47300	0.77027	0.80886	0.67619	1.0 / 24
Fold 1	0.51862	0.47424	0.76014	0.81218	0.67449	1.0 / 24
Pooled	0.51888	0.47362	-	-	-	3,814 samples

핵심 해석: Fold 간 Exact 차이는 0.00052로 설정 자체의 재현성은 높다. 반면 Pairwise 약 0.81과 Exact 약 0.52의 큰 간격은 개별 선후관계를 알아도 네 프레임 전체를 한 번에 맞추는 조합 오류가 남아 있음을 보여준다.

전체 학습과 추론

항목	검증된 값
전체 학습	9,535개 전부, validation 없음, 1 epoch, 9,535 optimizer steps
Optimizer	learning rate 2e-5, weight decay 0.01, seed 2026
시간	M1 Max 기준 학습 17.3시간, test 819 추론 38.3분
최종 산출물	base 1개 + LoRA adapter 1개(166MB) + processor + 독립 inference
제출 보장	819행, Id 순서 일치, 모든 Answer가 1-4의 완전 순열

재현성 통제

버전 고정: base commit·fold manifest·adapter SHA256를 report에 저장. **데이터 경계:** fold 학습과 설정 선택 단계에서 test CSV·이미지 접근 없음. **중단 복구:** adapter·optimizer·item index를 checkpoint에 저장하고 동일 run signature에서만 resume. **제출 감사:** inference record와 CSV의 819개 행을 byte-level lineage로 대조.

03 / EXPERIMENTS

좋아 보이는 점수보다 재현되는 개선을 선택

단일 패널 상승을 최종 기법으로 채택하지 않고, 별도의 C256에서 같은 방향이 재현되는지를 중단 기준으로 사용했다.

모델 계보: 시각 이해의 질이 만든 큰 도약

단계	대표 train-only panel Exact	역할 / 결론
SigLIP 기반 24순열 scorer	OOF 0.4918	빠른 자동 baseline, 세밀한 사건 순서 한계
Qwen2.5-VL-3B snapshot	B256 0.3125	경량 VLM이나 대표 패널에서 낮음
Qwen3-VL-8B snapshot	B256 0.3555	크기 증가 이득이 주로 원순서에 집중
Qwen3.5-9B, train 512	B256 0.4453	새 backbone-동일 제한 decoder의 첫 승격
Qwen3.5-9B, full Fold 0	1,907개 0.5191	최종 설정


위 snapshot들은 학습량이 달라 순수 backbone-only 비교가 아니라 의사결정 계보다. 최종 선택은 Qwen3.5가 대표 B256 승격 기준을 통과한 뒤 1,907개 Fold 0과 독립 Fold 1에서 다시 확인하는 순서로 이루어졌다.

추론 Ablation: B에서 오른 기법이 C에서 재현되는가

방법	B256 Exact	B 대비	C256 Exact	C 대비	최종 결정
Greedy 224 ²	0.5078	-	0.4609	-	채택
4-way input TTA	0.5391	+0.0313	0.4609	+0.0000	기각
24순열 exact likelihood	0.5273	+0.0195	0.4648	+0.0039	기각
TTA tie + exact-24	0.5508	+0.0430	0.4648	+0.0039	기각
336 ² high resolution	0.5430	+0.0352	미실행	-	B 안정성 gate 실패

B256만 보면 TTA tie + exact-24가 +4.30%p로 가장 좋아 보인다. 그러나 C256에서는 +0.39%p에 그쳤고, 4-way TTA는 7개를 고치는 동안 7개를 망쳐 순이득이 0이었다. 이 결과는 search budget보다 학습된 시간 표현 자체가 병목임을 보여준다. 최종 추론은 가장 단순한 greedy 224²로 고정했다.

Public 성능의 자동 모델 계보



Public 0.85863은 819개 test를 한 번에 자동 추론한 결과이며 개별 답 수정이 없다. Fold 0 자동 모델 0.846에서 전체 train fresh refit으로 +0.01263 상승했다. Public은 70%이므로 이 수치를 Private 보장값으로 해석하지 않는다.

04 / ANALYSIS

남은 오류는 '보지 못함'보다 '전체로 조립하지 못함'

Fold 0의 1,907개 row-level audit로 성능 병목과 최종 방법의 장점·한계를 분리했다.

0.8089

Pairwise accuracy

6개 선후관계 평균

0.5191

Exact Match

네 위치 모두 일치

41.1%

Adjacent-swap 오류

377 / 917 errors

구조적 오류 진단

관찰	Fold 0 결과	의미
Pairwise - Exact gap	0.28972	국소 선후관계가 전체 순열로 일관되게 결합되지 않음
Identity target / prediction	15.52% / 20.71%	원순서 +5.19%p 과예측
Identity / non-identity Exact	0.7703 / 0.4730	쉬운 원순서 성능과 실제 재배열 성능 간 격차
Error Kendall distance	평균 2.385	오답도 일부 관계는 맞지만 exact metric에서는 0점
인접 swap	377개, 오류의 41.1%	미세 동작 변화의 경계 판별이 주된 잔여 오류

대표 B256의 의미 기반 bucket

Bucket	n	Exact	해석
Camera motion	98	0.561	배경 흐름과 시점 변화가 비교적 강한 단서
Scene transition	180	0.511	장면 경계는 평균보다 쉬움
Person action	167	0.431	유사 자세 사이의 미세 변화가 어려움
Sports / water / snow	66	0.439	반복 배경과 빠른 동작이 혼동을 유발
Long sentence	5	0.200	표본이 작아 결론은 제한적이나 긴 사건 연결이 취약

장점

- 단일 모델이 입력부터 CSV까지 자동 처리
- trie 제한으로 형식·중복·누락 오류 원천 제거
- 독립 fold 차이 0.00052로 설정 재현성 확인
- 166MB adapter와 pinned base revision으로 배포 용이
- 한 패널 과적합 기법을 배제한 보수적 선택

한계와 다음 개선

- Public 0.85863과 train-only 0.519의 분포 차이 원인 미확정
- Private와 외부 데이터 성능은 아직 알 수 없음
- 224⁺ 상한은 작은 물체·미세 자세 정보를 잃을 수 있음
- 실제 RTX 3090 peak VRAM은 미측정
- 향후에는 pairwise 관계의 전역 일관성 학습이 핵심

결론

본 접근의 독창성은 거대한 VLM을 그대로 prompting한 데 있지 않다. **Exact Match**가 요구하는 24개 순열 구조를 생성 과정에 내장하고, 입력 위치 shortcut과 실제 prior 사이를 25% 라벨 보존 증강으로 조절했으며, 독립 재현 실패를 근거로 복잡한 추론 기법을 과감히 제거했다. 그 결과 수동 개입 없는 하나의 Qwen3.5-9B adapter로 Public **0.85863**을 달성했다. 남은 연구 과제는 국소 선후관계 0.81을 전체 순열 Exact로 손실 없이 결합하는 것이다.

Backbone: Qwen/Qwen3.5-9B, revision c202236235762e1c871ad0ccb60c8ee5ba337b9a, Apache-2.0

Reference: <https://huggingface.co/Qwen/Qwen3.5-9B>