

멀티모달 순열 생성과 신뢰도 기반 디코딩을 활용한

비디오 프레임 시간 순서 복원

VoLuMe up(박수현, 성유민, 이지우, 조호성)

초록

본 과제는 순서가 뒤섞인 네 장의 비디오 프레임과 설명문으로 실제 시간 순서를 복원하는 문제이다. 가능한 순열은 24 개지만, 인접 프레임 간 변화가 작고 의미가 유사해 단순 이미지 분류나 이미지-텍스트 대응만으로는 선후관계 판단이 어렵다.

본 연구에서는 Qwen3-VL-8B-Instruct 에 언어·비전 LoRA 를 적용하여 정답 순열을 직접 생성하도록 학습하였다. 입력 위치 편향을 줄이기 위해 24-view Test-Time Augmentation(TTA)을 수행하고, 각 view 의 시퀀스 로그확률을 활용해 동일 순열의 가중치를 합산하는 exact-match 지향 디코더를 구성하였다. 또한 검은 프레임이나 동일 프레임이 반복되는 모호한 샘플을 제거하고, 동일 프레임을 공유하는 영상이 학습·검증에 동시에 포함되지 않도록 검증셋을 구성하였다. 내부 검증 exact match accuracy 는 24-view 하드보팅의 0.3340 에서 0.3700 으로, private score 는 pairwise 기반 디코더의 0.85772 에서 0.91463 으로 향상되었다.

1. 문제 정의 접근 동기

1.1. 문제 특성과 기존 접근의 한계

초기에는 CLIP 과 SigLIP 을 이용해 24 개 순열 중 하나를 선택하였다. 그러나 같은 영상에서 추출된 프레임들은 내용이 유사해, 미세한 행동 변화와 사건의 선후관계를 구분하기 어려웠다. 또한 생성형 VLM 도 입력된 프레임이 Image 1 또는 Image 4 중 어느 위치에 놓였는지에 따라 서로 다른 답을 생성하는 입력 위치 편향을 보였다.

1.2. 핵심 기여 및 장점

- 프레임 순서 배열을 24-class 분류 대신 이미지와 Sentence 로 프레임 순열을 직접 출력하는 멀티모달 시퀀스 생성 문제로 정의하였다.
- 입력 순서 증강과 24-view TTA 를 결합하여 입력 위치 편향을 줄였다.
- 각 TTA view 의 생성 로그확률을 신뢰도로 반영하여, 가장 높은 가중 점수를 얻은 순열을 최종 답으로 선택하는 디코더를 설계하였다.

데이터 정제	순서 증강	Qwen3-VL + LoRA	24-view TTA	Exact 디코더
밝기·MD5·dHash	Shuffle / Identity	3 epoch SFT	예측 + logprob	최종 Answer

2. 데이터 활용 및 모델 설계

2.1. 파이프라인



2.2. 데이터 전처리 및 정제 전략

학습 데이터는 9,535 개 샘플과 38,140 개 프레임으로 구성되어 있다. EDA 를 통해 정답 순열, No_ordering, Sentence 길이, 이미지 품질과 프레임 중복 구조를 분석하였다. Identity 순열 [1,2,3,4]는 1,478 개로 전체의 15.50%였고, Sentence 는 결측치가 없었고 평균 길이는 24.15 단어였다.

이미지의 평균 밝기, 밝기 표준편차, 엔트로피, 선명도와 MD5 및 dHash 분석 결과, 검은 프레임 혹은 서로 동일하거나 유사한 프레임이 일부 존재하였다. 검은 프레임은 평균 밝기가 10 미만이고 표준편차가 15 미만인 이미지로 정의하여, 해당 프레임이 한 샘플에 2 장 이상 포함되거나 샘플 내부에서 MD5 또는 dHash 가 일치하는 프레임이 반복되는 경우를 정답 순서가 모호해지는 노이즈로 판단하여 제거하였다. 총 140 개 샘플을 제거해 최종 9,395 개의 정제 데이터를 확보하였다.

전처리 항목	판정 기준·적용 방식	목적	채택 여부
--------	-------------	----	-------

반복 검은 프레임 제거	평균 밝기<10, 표준편차<15 인 프레임이 한 샘플에 2 장 이상 존재	구분할 수 없는 검은 프레임 간 정답 모호성 제거	O
이미지 품질 기반 제거	밝기·엔트로피·선명도 임계값	정보가 부족한 저품질 프레임 제거	X
Gray-World white balance	RGB 채널별 평균을 동일하게 보정	색온도 보정을 통한 조명 차이 완화	X
샘플 내 이미지 완전 중복 제거	MD5 일치	동일 시점의 반복으로 인한 모호성 제거	O
샘플 내 이미지 근접 중복 제거	dHash 거리 활용	미세한 차이만 있는 프레임 간 정답 순서 모호성 제거	O
샘플 간 이미지 완전 중복 제거	MD5 일치	동일 영상 구간의 반복 학습으로 인한 데이터 편향 완화	X
텍스트 중복 제거	정규화된 sentence 중복 여부 검사	텍스트 암기 및 누수 가능성 확인	X
레터박스 크롭	검은 테두리 자동 crop	유효 해상도 확보	O
종횡비 보존 처리	고정 크기 변형 대신 픽셀 예산 사용	인물, 물체의 형태 왜곡을 최소화	O
해상도	학습 시 768×432 추론 시 1280×720	학습 효율을 확보하면서 추론 시 세부 시각 정보 보존	O

2.3. 학습/검증 분할과 재현성

다른 샘플과 유효 프레임을 공유하지 않는 4,721 개만을 검증 후보군으로 구성하였고, 전체 데이터의 No_ordering 비율이 유지되도록 500 개를 층화 추출하였다. 모든 분할 과정은 random seed = 42 로 고정하여 동일한 데이터 구성과 실험 결과를 재현할 수 있도록 하였다.

초기에는 무작위 분할을 적용하였으나, 모델이 학습 중 관찰한 프레임 또는 매우 유사한 프레임을 검증 단계에서 다시 보게 되어 성능이 과대적합될 수 있어 해당 방법을 취하였다.

항목	원본	정제/분할 후
샘플 수	9,535 개	9,395 개
검증셋	-	500 개
학습셋	-	8,895 개

2.4. 모델 구조와 LoRA 적용

InternVL 계열은 동일한 검증 분할, 프롬프트, 출력 파싱 조건에서 파인튜닝 전 EM 을 비교하였다. 14B 모델이 일반 8B 모델보다 높았으나, MPO 가 적용된 InternVL2.5-8B-MPO 가 14B 모델을 상회하여 1 차 후보로 선정하였다. 파인튜닝 후 검증 EM 0.5580, private score 0.86736 을 기록하였다. 주목할 점은 파라미터 규모와 성능이 비례하지 않았다는 것이다. 이는 본 과제의 병목이 모델 용량이 아니라 시각-언어 정렬의 품질에 있음을 시사한다.

모델	EM
InternVL2.5-8B-MPO	0.3125
InternVL3.5-14B	0.3000
InternVL3.5-8B	0.2400

Qwen3-VL-8B-Instruct 는 동일 조건의 직접 비교는 아니었으나 별도 실험에서 유사한 성능을 보였다. 또한 대회 공개 기준일 이전인 2025 년 10 월 15 일에 공개되었으며, 연산 요구가 비교적 낮고 이미지별 토큰 수를 제어할 수 있어 최종 기본 모델로 선정하였다.

제한된 연산 자원에서 모델을 효율적으로 적응시키기 위해 전체 파라미터 파인튜닝 대신 언어·비전 모듈에 LoRA 를 적용하였다.

$$W' = W + (a/r)BA$$

기존 가중치 (W)는 고정하고 저차원 행렬 (A)와 (B)만 학습하였다. 언어부 252 개와 비전부 116 개 등 총 368 개 모듈에 동일한 rank 의 LoRA 를 적용하여, 전체 8,819,617,520 개 파라미터 중 52,493,824 개(0.595%)만 학습하였다.

초기에는 언어부에만 LoRA 를 적용했으나 미세한 시각 변화의 학습이 제한되어 비전 인코더까지 적용 범위를 확대하였다. 학습 환경에 따라 BF16 LoRA 또는 NF4 4-bit QLoRA 를 사용할 수 있도록 구성하였다.

3. 학습 및 추론 과정

3.1. 학습 입력 구성과 손실

모델 입력은 네 장의 이미지, Sentence 와 문제 지시문으로 구성하였다. 프롬프트에는 Sentence 속 사건의 전후 순서, 원인과 결과, 행동 진행 정도, 자세, 위치, 장면 전환, 조명 및 화면 문자 등의 단서를 활용하도록 명시하였다. 출력은 [3, 1, 4, 2]와 같은 시간순 이미지 번호만 생성하도록 제한하였다.

프롬프트 토큰은 labels=-100 으로 마스킹하여 loss 에서 제외하고, 정답 리스트 토큰에 대해서만 causal language modeling loss 를 계산하였다. 따라서 모델은 입력된 문제 지시문을 다시 생성하는 것이 아니라, 이미지와 Sentence 를 바탕으로 올바른 이미지 순서만 예측하도록 학습된다.

3.2 입력 순서 증강

입력 위치 편향을 줄이기 위해 두 가지 증강을 적용하였다. Shuffle augmentation 은 No_ordering=False 인 샘플의 프레임 순서를 매 epoch 무작위로 변경해 입력 슬롯 편향을 줄였다. Identity augmentation 은 일부 샘플을 시간순으로 배치하고 정답을 [1,2,3,4]로 설정하여, 모델이 무조건 입력 순서를 재배열하는 편향을 막았다.

3.3. 학습 설정

항목	설정	항목	설정
Epoch	3	Learning rate	1×10^{-4}
Scheduler	Cosine	Warm-up	0.03
유효 batch	8	LoRA dropout	0.05
학습 픽셀 예산	768×432	추론 픽셀 예산	1280×720

각 epoch 종료 시 LoRA 어댑터를 별도로 저장하여, epoch 별 어댑터와 그 가중치 평균(soup)을 검증셋에서 비교할 수 있도록 구현하였다.

3.4. 24-view TTA 와 신뢰도 기반 디코딩

추론에서는 균형 있게 선정한 8 가지 입력 순서와 가능한 24 가지 입력 순서를 모두 사용하는 방식을 비교하였다. 각 예측은 원본 이미지 번호 기준으로 변환하여 집계하였다.

각 view 에서 예측한 순열과 함께 해당 순열의 생성 로그확률을 저장하였다. 모델이 답을 생성하는 과정에서 계산되어, 별도의 추가 forward 연산 없이 각 view 의 예측 신뢰도로 활용할 수 있었다.

집계 방식으로는 쌍별 선호 위배를 최소화하는 Kemeny 방식과 동일 순열을 예측한 view 의 가중치를 합산하는 순열 단위 방식을 비교하였다.

view v 의 생성 순열을 π_v , 로그확률을 l_v 라 두고 상대 신뢰도를 $\exp(l_v - \max_j l_j)$ 로 변환한 뒤, 신뢰도 반영 강도를 조절하는 하이퍼파라미터 $\text{conf_power } \gamma$ 를 적용하여 view 의 가중치를 계산하였다. 후보 순열 π 의 점수는 해당 순열을 정확히 생성한 view 의 가중치 합으로 계산하고 합 최대인 순열을 최종 답으로 선택하였다.

$$w_v = [\exp(l_v - \max_j l_j)]^\gamma$$

$$S(\pi) = \sum_v 1(\pi_v = \pi) w_v$$

검증셋 EM 기준으로 $\gamma \in \{0, 0.5, 1, 2, 3, 4, 6\}$ 을 탐색하였다. $\gamma=0$ 이면 모든 view 에 동일한 가중치가 부여되어 하드보팅과 같고, 값이 커질수록 신뢰도가 낮은 view 의 영향이 줄어든다.

Identity 순열의 점수에 전체 가중치 합의 일정 비율을 추가하는 identity_frac 과, dHash 거리가 6 이하인 근접중복 프레임이 있는 샘플의 점수를 보정하는 dup_frac 도 함께 탐색하였다. 총 탐색 조합은 $7 \times 10 \times 7 = 490$ 개이다.

CoT refinement 는 low-margin 샘플에만 적용하였다. top1 과 top2 의 점수 차가 전체 가중치 합의 12% 미만이면 CoT 프롬프트로 한 번 더 추론하고 해당 답에 전체 가중치 합의 30%를 추가하였다. 전체 샘플에 적용하면 연산량이 크게 늘고 고신뢰 예측까지 바뀔 수 있으므로 불확실한 샘플만 적용하였고, 검증셋에서 손해가 아닐 때만 활성화되도록 하였다.

4. 실험 결과 및 분석

4.1. 주요 결과

모델 soup 보다 3 epoch 학습을 마친 단일 어댑터의 성능이 가장 높아 이를 채택하였다. 추론이 단일 가중치로 1 회 수행되므로 여러 모델의 추론 결과를 조합하는 앙상블에 해당하지 않으며, 배포 구조 또한 단순하다.

방법	Validation EM	Validation Pairwise	Private score	해석
1-view 추론(TTA 미적용)	0.3200	0.7090	-	입력 위치 편향 보정 없는 기준
24-view pairwise consensus	0.3180	0.7140	0.85772	Pairwise 향상에도 EM 하락
24-view hard voting	0.3340	-	-	view 별 신뢰도 차이 반영 불가
24-view + 로그확률 가중치	0.3600	-	0.91463	저신뢰 view 영향 실질적 소거
+ identity·dHash 보정	0.3600	-	-	계수 0 선택 — 이득 없음
+ CoT refinement	0.3700	-	0.91463	애매한 샘플에 한정해 재추론

동일한 학습 어댑터에서 추론 집계 방식만 변경한 결과, 검증셋 EM 는 24-view 하드보팅에서 0.3340, 로그확률 가중 디코딩에서 0.3600, low-margin CoT refinement 를 추가한 구성에서 0.3700 으로 향상되었다. 이는 재학습 없이 하드보팅 대비 0.0360(3.6%p) 개선된 결과이다. Private score 도 pairwise consensus 기반 디코더의 0.85772 에서 순열 단위 디코더의 0.91463 으로 0.05691 상승하였다.

conf_power 탐색에서는 $\gamma=4.0$ 이 가장 높은 검증 성능을 보였다. $\gamma=1$ 이 로그확률의 우도비를 그대로 반영하는 값임을 고려하면, 낮은 신뢰도의 view 를 더 강하게 감점하는 방식이 효과적이었음을 알 수 있다. 출력이 짧고 형식 토큰의 비중이 높아 view 간 로그확률 차이가 작게 나타났으며, $\gamma=4.0$ 이 이러한 차이를 확대해 반영한 것으로 해석된다.

한편 EM 성능을 높이려면 개별 프레임 쌍이 아닌 순열 전체를 기준으로 예측을 집계해야 한다. 실제로 24-view pairwise consensus 는 단일 추론보다 pairwise 정확도는 높았지만 EM 은 낮아, 쌍별 정확도 향상이 전체 순열 정확도로 이어지지 않음을 보여주었다.

4.2. Ablation Study

로그확률 가중은 검증 EM 을 0.3340 에서 0.3600 으로 높여 전체 개선 중 2.6%p 를 차지하였다.

identity_frac 과 dup_frac 은 -0.3 까지의 음수 범위까지 탐색했으나 모두 0.0 에서 최적이었으며, 추론 단계의 추가 보정은 효과가 없었다. 이는 학습 단계의 identity augmentation($p=0.10$)으로 관련 패턴이 이미 반영되었기 때문으로 해석된다.

Low-margin CoT 는 검증셋에서 5 개 샘플을 추가로 맞춰 0.3600 에서 0.3700 으로 향상되었다. 그러나 public score 는 573 개 중 1 개만 변화했고(0.93019→0.93193), private score 는 동일하여 기여가 제한적이었다.

No_ordering 판정에서 pairwise 디코더는 recall 0.558, precision 0.339 로 전체의 25.4%를 identity 로 예측해 실제 비율 15.5%를 크게 웃돌았다. 로그확률 exact 디코더는 recall 0.532, precision 0.477 로 recall 감소를 제한하면서 오답을 줄였다. identity 오답이 곧 전체 오답이 되므로, 이러한 precision 개선이 성능 향상으로 이어졌다.

4.3. Error Analysis

Sentence 길이	샘플 수	Single Exact
0-10 words	95	0.2211
11-25 words	276	0.3043
26-100 words	129	0.4574

오류는 Sentence 에 시간 단서가 부족하거나 프레임 간 시각적 차이가 미세한 경우에 집중되었다. 대표적으로 ① 손·공·얼굴 방향 등 인접 프레임의 변화가 작은 경우, ② ‘사람들이 운동하고 있다’처럼 상태만 묘사한 짧은 Sentence, ③ 장면 전환·반복 편집·구도 변화로 행동의 연속성이 약한 경우가 있었다. 반면 사건 전개가 구체적인 Sentence 는 각 사건과 프레임을 대응시키기 쉬웠다.

Top-k 후보 순열을 teacher-forced log probability 로 재평가하는 reranker 도 실험하였다. 별도 검증에서 변경된 7 건 중 정답으로 수정된 사례는 1 건이었으며, 2 건은 정답에서 오답으로, 4 건은 오답 간에

변경되었다. 표본이 작아 단정하기는 어렵지만, 전체 순열을 재평가하기보다 Top-1 과 Top-2 를 구분하는 특정 프레임 쌍을 재검증하는 방향이 더 유망할 가능성을 확인하였다.

5. 자원 효율성

전체 8B 모델 중 약 0.595%의 파라미터만 학습하므로 전체 fine-tuning 보다 학습 메모리와 체크포인트 저장 비용이 작다. 메모리가 제한적인 환경에서는 4-bit QLoRA 를 사용할 수 있으며 gradient checkpointing 과 gradient accumulation 으로 VRAM 사용량을 조절하였다. 24-view TTA 는 단일 추론보다 계산량이 증가하지만 view 별 결과를 캐시하고 로그확률을 생성 과정에서 동시에 추출하여 재실행 비용을 줄였다.

항목	설정 또는 측정값
기본 모델	Qwen3-VL-8B-Instruct
학습 파라미터	52,493,824 개 / 전체의 0.595%
학습 epoch	3
Test 샘플 / 총 view	819 / 19,656
학습 GPU·Peak VRAM	코랩 G4
총 학습 시간	약 3.33 GPU-hour
Test 전체 추론 시간	약 4 GPU-hour
외부 데이터·API 비용	미사용 / 0 원

6. 한계

24-view 추론은 단일 추론보다 지연 시간과 연산량이 크며, dHash 기반 근접중복 판정은 미세하지만 의미 있는 시간 변화를 완전히 구분하지 못한다. 또한 설명문이 짧거나 프레임 간 변화가 작은 경우 선후관계 판단이 어렵다. 향후에는 Top-1 과 Top-2 가 충돌하는 프레임 쌍만 재검증하는 local pair verifier, 적응형 view 선택, 설명문의 사건 단위 구조화를 통해 계산량과 오류를 줄일 수 있다.

7. 결론

본 연구는 순서가 뒤섞인 네 장의 비디오 프레임과 설명문으로 실제 시간 순서를 복원하는 문제를, 24 개 순열 중 하나를 선택하는 대신 정답 순열을 직접 생성하는 방식으로 해결하였다. 데이터 정제와 누수 방지 검증셋 구성, 시각·언어 LoRA, 입력 순서 증강, 24-view TTA, 로그확률 가중 디코딩을 결합하여 private score 0.91463 을 달성하였다. 이는 더 큰 모델이나 외부 데이터 없이도 입력 위치 편향과 EM 평가 방식에 맞춰 학습 및 추론 과정을 설계하는 것이 성능 향상에 중요함을 보여준다.

참고문헌

- [1] Radford, A., Kim, J. W., Hallacy, C., et al. (2021). Learning Transferable Visual Models From Natural Language Supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.
- [2] Hu, E. J., Shen, Y., Wallis, P., et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations (ICLR)*.
- [3] Wortsman, M., Ilharco, G., Gadre, S. Y., et al. (2022). Model Soups: Averaging Weights of Multiple Fine-tuned Models Improves Accuracy Without Increasing Inference Time. *International Conference on Machine Learning (ICML)*.
- [4] Chen, Z., Wang, W., Tian, H., et al. (2024). InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [5] Wang, W., Chen, Z., Wang, W., et al. (2024). Enhancing the Reasoning Ability of Multimodal Large Language Models via Mixed Preference Optimization. *arXiv:2411.10442*.
- [6] Wei, J., Wang, X., Schuurmans, D., et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [7] Song, Y., Du, Y., Paperno, D., & Gatt, A. (2025). Burn After Reading: Do Multimodal Large Language Models Truly Capture Order of Events in Image Sequences? *arXiv:2506.10415*.