

# SNU AI Challenge 보고서

## 팀 “후디의 집사들”

### 1. 서론

본 보고서는 SNU AI Challenge에서 최고점(0.86212점)을 달성한 ‘Qwen3-VL-4B (QLoRA) + TTA’ 기반의 방법론을 소개합니다. 저희는 데이터셋 증강과 판별 문구 추가라는 직관적 접근으로 베이스라인을 구축한 뒤, 이를 넘어서기 위해 CoT(Chain-of-Thought) 등 심화 기법을 시도했으나 모두 최고점을 넘지 못했습니다. 본 연구는 이 실패를 통제된 실험으로 분석하여, 과제 이면에 숨겨진 ‘정보 손실 병목’이라는 구조적 한계를 발견합니다.

모든 미세조정(SFT)은 단일 RTX 4070Ti(12GB VRAM) 환경에서 QLoRA로 진행되었으며, 통계적 신뢰성을 위해 자체 구축한 val\_split을 기준으로 분석을 수행했습니다. 또한, 단순한 전체 정답률(EM)을 넘어 순서가 없는 그룹(True)과 있는 그룹(False)을 철저히 분리하여 모델의 취약점을 입체적으로 해부했습니다.

### 2. Zero-shot 진단: 능력 부재인가, 임무 미학습인가

사전학습만 된 Qwen2-VL-2B 모델로 test를 추론한 결과, 예측의 77%가 [1,2,3,4](순서 없음)로 편향되는 ‘회피(도망)’ 현상을 발견했습니다. 이를 val\_split에서 분해해 본 결과는 다음과 같습니다.

**전체 EM 12.47% / True(순서 없음) 76.35% / False(순서 있음) 0.74%** 맞힌 케이스조차 대부분 회피가 우연히 적중한 것(True 정답률  $\approx$  도망률)이었으며, 실제 추론이 필요한 False 그룹은 무작위 확률(4.16%)보다 낮았습니다. 상위 모델(Qwen3-VL-4B) 교차 검증에서도 False 그룹은 0.62%에 불과해, 체급과 무관하게 순서 추론 능력이 사실상 ‘0’임을 확인했습니다. 이 진단을 바탕으로, 병목이 ‘지능’이 아닌 ‘임무 미학습’에 있다고 판단하여 ① SFT를 최우선으로 수행하고, ② 순수 추론 능력을 대변하는 False 그룹 정확도를 핵심 지표로 삼았으며, ③ 잔존하는 회피 성향은 판별 프롬프트로 교정하는 최적화 전략을 수립했습니다.

### 3. SFT 도입 및 인지 편향(도망 현상) 교정

**3.1. 2B 모델 사전 검증 및 캘리브레이션** 우선 가벼운 2B 모델로 1차 SFT를 수행한 결과, True 그룹(76.35%)은 그대로인 채 False 그룹만 정확도가 0.74%에서 26.80%로 36배

폭증하며 추론 능력 주입에 성공했습니다. 잔존하는 회피 성향을 억제하기 위해 순서가 존재하는 샘플을 재서플하여 학습 데이터를 **2배로 증강**(위치 불변성)하고, 확신이 없을 때만 [1,2,3,4]를 답하도록 **명시적 판별 문구**를 삽입했습니다. 그 결과, 과도한 예측 횟수가 실제 분포에 가깝게 수렴하며 정밀한 순서 추론(False) 능력이 +10.3%p 대폭 상승했습니다.

**3.2. 타겟 모델(4B) 이식 및 베이스라인(run4) 구축** 처방의 유효성이 검증됨에 따라, 동일 파이프라인을 Qwen3-VL-4B(QLoRA 4-bit)에 이식했습니다. test 후반부의 고해상도(최대 6.8배) 이미지로 인한 OOM 방지를 위해 768px 사전 축소 로직(load\_capped)을 도입했으며, 그 결과 단일 모델 기준 **Validation EM 0.517, LB 0.8569**라는 강력한 토대(run4)를 완성했습니다.

4. 성능 한계 돌파를 위한 통제 실험과 '정보 손실 병목'

run4를 통해 성공적으로 베이스라인(Val 0.517)을 구축한 이후, 모델의 추론 능력을 극대화하기 위해 CoT, Pairwise 분해 등 다양한 심화 기법을 도입했습니다. 그러나 역설적이게도 데이터나 추론 과정을 가공하려는 모든 시도는 심각한 성능 저하를 초래했습니다. 저희는 엄밀한 통계 검정을 통해, 이 실패들이 '정보 손실 병목(Information-Loss Bottleneck)'이라는 단일 원리로 수렴함을 밝혀냈습니다.

| 실험(개입)방식              | Val EM(전체 정답률) | Run4 대비 증감  | 분석 결과            |
|-----------------------|----------------|-------------|------------------|
| Run4(Holistic, 베이스라인) | 0.517          |             |                  |
| CoT(언어적 직렬화)          | 0.233          | -0.284      | 언어 대역폭 한계로 정보 훼손 |
| 해상도 ↑ 40% (추론)        | 0.508          | -0.009      | 픽셀은 병목 아님        |
| no-order 재균형 (데이터)    | 0.514          | -0.003      | 이미 최적 임계점        |
| Pairwise(맥락 파편화)      | 0.374          | -0.143      | 전역 맥락 상실 및 오차 누적 |
| 모델 배선 확장 (Expanded)   | 0.520          | +0.003(무의미) | 지각·추론 용량 병목을 시사  |

<표 1> 통제 실험 요약(전 수치 val 954 전수, run4=0.517 기준)

**4.1. 시각 정보의 언어적 직렬화 한계 (CoT 및 모달리티 교차 검증)** 모델이 이미지의 상태를 스스로 서술하고 추론하게 만드는 CoT(Chain-of-Thought) 기법을 적용한 결과, 정확도는 오히려 27.5%p 폭락(Val 0.233)했습니다. 그 원인은 다음과 같습니다.

- **텍스트 채널의 한계:** 캡션 등 언어는 "장면에 무엇이 있는가(내용)"는 담아내지만, 순서 추론의 핵심인 "시간이 어느 방향으로 흐르는가(미세 상태 변화)"는 담지 못했습니다.
- **모달리티 교차 검증:** 이미지 없이 캡션+문장만 준 실험(Text-only)은 성능이 크게 미달(0.405)했고, 학습 모델에 캡션을 보조로 넣은 실험 역시 아무런 이득(0.490)이 없었습니다. 즉, 미묘한 시각 단서를 억지로 텍스트(언어)로 풀어쓰도록 강제하는 과정 자체가 심각한 정보 훼손을 유발했습니다.
- **사후 정당화(Rationalization):** 본 CoT 설계는 정답(gold)에서 순서 라벨을 채워 생성했기에, 모델이 시각 증거로부터 순서를 도출하는 대신 이미 주어진 답을 사후 정당화하는 법만 학습한 것도 직접적인 원인이었습니다.

**4.2. 통합적 맥락의 파편화 (Pairwise 분해의 구조적 열세)** 4장의 이미지를 한 번에 정렬하는 작업의 복잡도를 낮추기 위해, 모델에게 2장씩 짝지어(6쌍) 시간의 선후 관계를 묻는 2지선다(Pairwise) 방식으로 문제를 재정의했습니다. 그러나 동일 에폭(Epoch)으로 공정 비교를 수행해도 전체 정확도는 12.7%p 하락했습니다.

- **전역 맥락 상실:** 4장의 이미지는 전체 문장과 융합될 때만 온전한 시간적 의미를 갖습니다. 문제를 2장씩 쪼개는 순간 주변 이미지와 상호작용하며 얻는 전역 맥락(Global Context)이 상실되었습니다.
- **오차 누적 구조:** Exact Match(EM) 채점 방식의 특성상 6번의 판정 중 한 번의 오차만 발생해도 전체가 오답 처리되는 구조적 한계에 부딪혔습니다.

## 5. 고난도 샘플(Hard Examples) 국소화와 근본적 한계 규명

여러 개입이 실패하는 근본 원인을 파악하기 위해, 모델이 어떤 문제에서 오답을 내는지 추적했습니다.

**5.1. 미세 시간 진행 판별의 실패 (프레임 유사도 분석)** 저희는 서로 다른(연관성 낮은) 장면들은 공통의 시간축이 없어 순서대로 엮기 더 어려울 것이라 예상하고, 순서가 존재하는 샘플을 프레임 간 유사도(Caption Jaccard 평균) 기준 4분위로 나누어 정확도를 측정했습니다. 그러나 예상과 정반대의 결과를 얻었습니다.

- **쉬운 샘플 (Q1):** 장면이 확연히 다를 경우 74.4%의 높은 정답률을 보였습니다.
- **어려운 샘플 (Q4):** 동일한 장면 내에서 미세한 시간 변화가 일어나는 고유사도 샘플에서는 정답률이 25.6%로 급락했습니다. 이는 현재 모델의 병목이 단순한

지각(픽셀 해상도)의 문제가 아니라, '같은 장면 내에서 시간의 인과 방향을 추론하는 인지 능력 자체'에 있음을 강력히 시사합니다.



<그림 1>. 모델이 순서 추론에 실패한 전형적인 고난도 샘플(Q4) 예시(Id : aaJKPZ). 4장의 이미지가 시각적으로 거의 동일하여, 단순한 픽셀 지각이나 텍스트 캡션만으로는 시간의 인과 방향(어느 프레임이 먼저인지)을 특정할 수 없다.

## 5.2. 모델 배선 확장(Expanded LoRA)과 No-order의 본질

- **모델 배선 확장 실패:** 병목이 LLM의 얇은 어댑터(q/v)에 있을 가능성을 배제하기 위해, 비전 인코더와 LLM을 잇는 Merger 모듈 및 LLM 전체 배선으로 LoRA 타겟을 11배 확장하여 학습했으나 순서 추론 능력은 개선되지 않았습니다(-1.9%p).
- **제로섬(Zero-sum) 양상:** 데이터 분포 보정(증강된 학습 데이터 No-order True 그룹 비율 8.4% -> 15.5%), 추론 해상도 증가( $\uparrow 40\%$ ) 등 다양한 개입을 시도했으나, 모두 "No-order 예측이 늘면 순서 예측이 감소하는" 제로섬 양상을 보였습니다.
- **원인 및 결론:** 그 근본 원인은 No-order와 순서 그룹이 시각적으로 겹쳐 있어(프레임 유사도 평균 0.165 대 0.160) 분리할 수 없기 때문입니다. 즉, 모델은 No-order를 명확히 판별하는 것이 아니라 확신이 없을 때 [1, 2, 3, 4]로 치는 '보정된 도망'을 치고 있으며, 베이스라인(run4)이 이미 최적 임계점(Optimal Threshold)에 도달해 있음을 확인했습니다.

# 6. 방법론의 장점과 한계

## 6.1. 장점

본 방법론은 이미지를 쪼개거나 텍스트로 변환하지 않고 한 번의 연산으로 융합하는 무

가공 통합(Holistic) 접근의 강건성을 띠며, 맹목적 튜닝이 아닌 Zero-shot 진단 및 짝지은 검정 기반의 **엄밀한 의사결정**, 그리고 QLoRA 및 지연 로딩을 활용한 **향상된 엔지니어링 효율성**을 자랑합니다.

## 6.2. 한계 (남은 과제)

- **'용량 병목' 미확증:** 모든 축을 소거해 '병목은 4B 모델 자체의 용량'이라 추론했으나, 8B 등 상위 체급으로 실측 증명하지는 못했습니다.
- **Val-LB 성능 간극:** 자체 Val(0.517)과 LB(0.856) 사이의 +34%p 간극 원인으로 test 셋 후반부의 고해상도 분포를 검토했으나 두 방향(추론 해상도 향상 무효, 고/저해상도 예측 분포 동일)으로 기각되었고, test 라벨 부재로 인해 최종 원인은 미해명으로 남습니다.
- **초기 실험 교락 및 비전 인코더 미탐색:** 초기 2B 검증 시 다수 변수를 동시 적용해 원인 귀속이 어려웠던 점(후기 실험에서 통제 교정함), 그리고 비전 인코더 내부 동결로 인해 인코더 자체의 미세 시간 단서 추출 능력을 직접 검증하지 못한 점이 과제로 남습니다.

## 7. 결론: 최종 산출물 및 시사점

결론적으로, 전처리나 가공 없이 통째로 융합하는 베이스라인(run4)이 본 체급에서 낼 수 있는 최선의 해답이었습니다. 여기에 추론 노이즈를 안정화하기 위해 TTA(Test-Time Augmentation) 를 유일한 추가 기법으로 결합했습니다. 한 샘플의 4장을 K=3개 배열(원본+셔플)로 각각 추론한 뒤 원배치로 역매핑해 다수결을 내는 방식으로, 정보를 가공·왜곡하지 않고 단일 모델에 입력 변형만 가하였습니다. 그 결과 run4 단독 대비 **Public +0.5%p · Private +1.2%p**의 이득을 더해, 최종 **Private 0.85772 / Public 0.86212**의 최고 성과를 달성했습니다. 본 연구는 "무엇을 더해야 하는가"를 넘어, "**무엇으로는 벽을 넘을 수 없는가**"를 엄밀한 통제 실험으로 규명한 방법론적 독창성에 그 진정한 의의가 있습니다.